

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
PROGRAMŲ SISTEMŲ STUDIJŲ PROGRAMA

Skaitmeninio intelekto dirbtinių neuronų tinklo mokymo ataskaita

Darbo ataskaita

Atliko: 3 kurso 3 grupės studentas
Hubertas Vindžigalskis

Vilnius – 2025

Turinys

1. UŽDUOTIES TIKSLAS	3
2. PRADINIAI DUOMENYS	4
3. UŽDUOTIES SEKOS	5
3.1. Daugiasluoksnio perceptrono mokymo rezultatai:	8
3.2. Daugiasluoksnio perceptrono testavimo rezultatai:.....	9
3.3. Eksperimentai su hiperparametrais	10
3.4. Testavimo duomenų įrašų klasifikavimas	11
3.5. Duomenų atvaizdavimas dekartio koordinatinių sistemoje	11
3.6. Metodų palyginimas	15
4. IŠVADA	17

1. Užduoties tikslas

Užduotyje reikia ištreniruoti dirbtinių neturonų tinklą atpažinti irisų veisles pagal jų charakteristikas. Užduočiai įgyvendinti naudosime „KNIME Analytics platform“ programą.

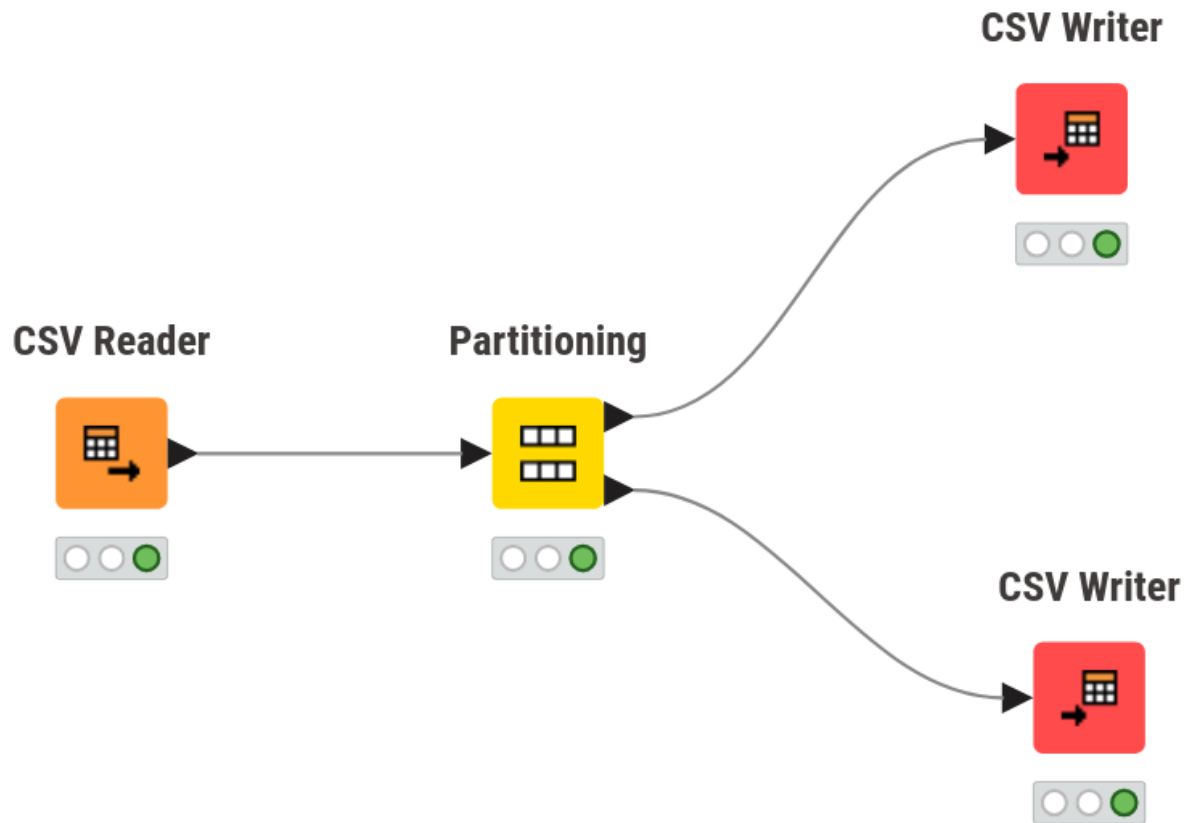
2. Pradiniai duomenys

Pradiniai duomenys gauti iš archive.ics.uci.edu. Jie sudaryti iš penkių stulpelių: lapkočio ilgio, lapkočio pločio, žiedlapių ilgio, žiedlapių pločio ir iriso veislės pavadinimo. Duomenys padalinti į du atskirus failus skirtus mokymui ir testavimui naudojant „Partitioning“ (skaidymo) mazgą. Padalinę gavome, jog mokymui paskyrėme 120 duomenų įrašų, o testavimui 30.

3. Užduoties sekos

2

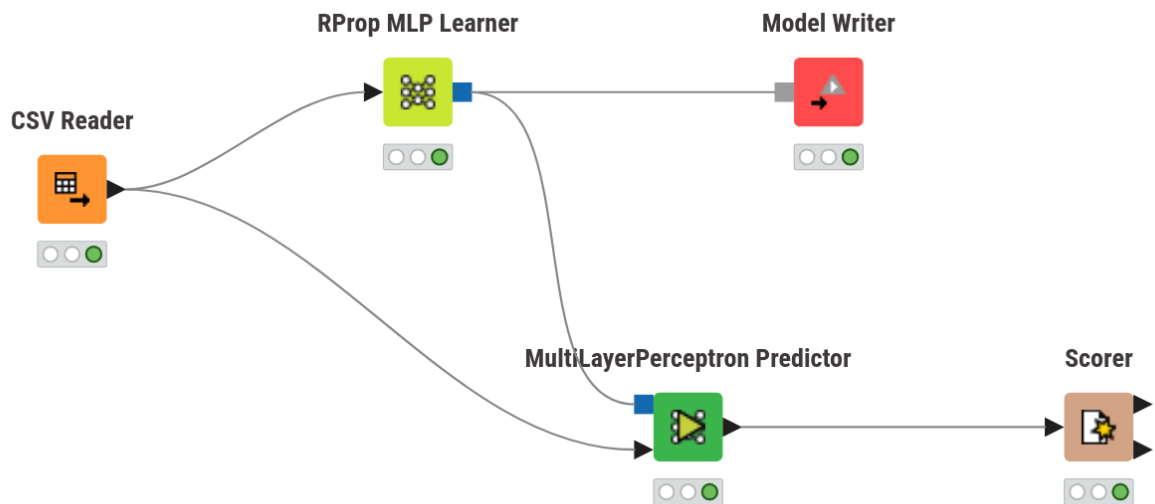
1 pav. CSV Reader mazgas nuskaito duomenis iš CSV failo, Partitioning mazgas padalija duomenis į dvi dalis, o kiekviena dalis išsaugoma atskirais CSV Writer mazgais.



1 pav. Antroji seka

3

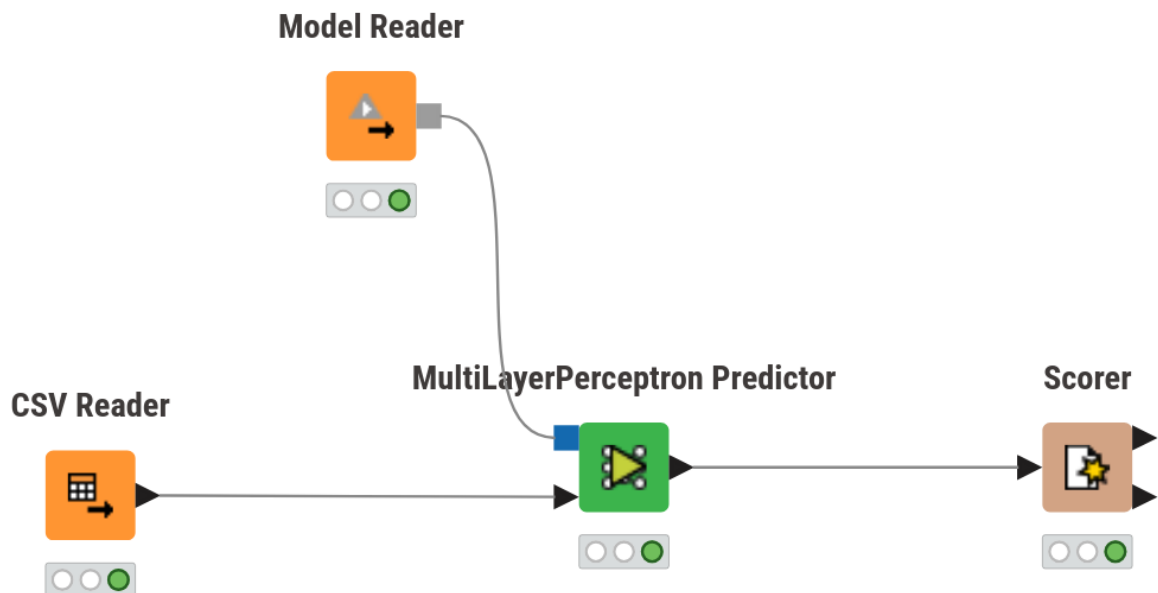
2 pav. CSV Reader mazgas nuskaito mokymo duomenis iš CSV failo, RProp MLP Learner apmoko daugiasluoksnį perceptroną, Model Writer išsaugo išmokytą modelį, o MultiLayerPerceptron Predictor bei Scorer atlieka prognozes ir įvertina rezultatus.



2 pav. Trečioji seka

4

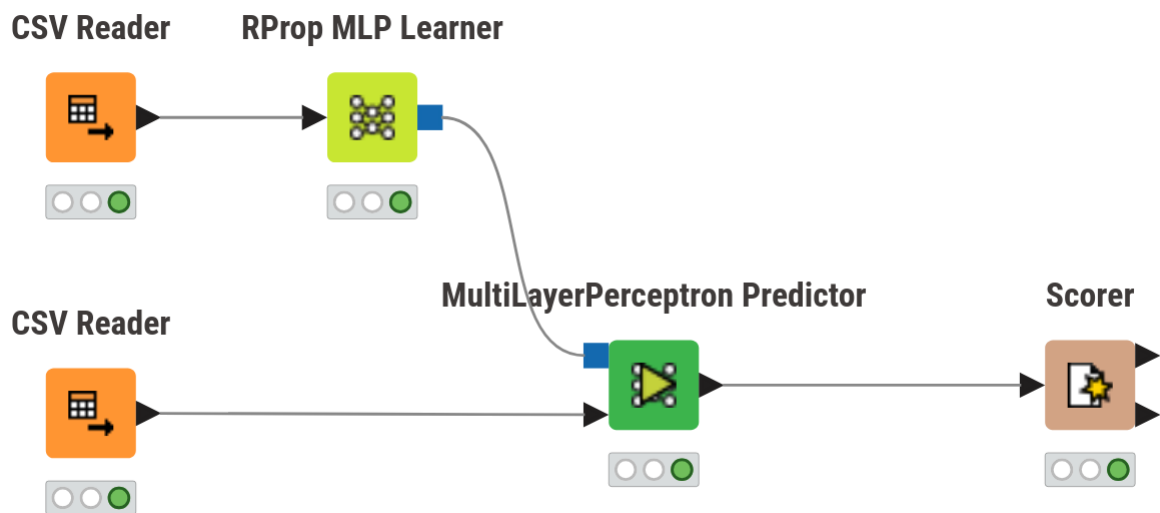
3 pav. CSV Reader mazgas nuskaito testavimo duomenis iš CSV failo, Model Reader mazgas įkelia išsaugotą daugiasluoksnio perceptrono modelį, MultiLayerPerceptron Predictor naudoja šį modelį prognozėms, o Scorer įvertina gautus rezultatus.



3 pav. Ketvirtoji seka

5

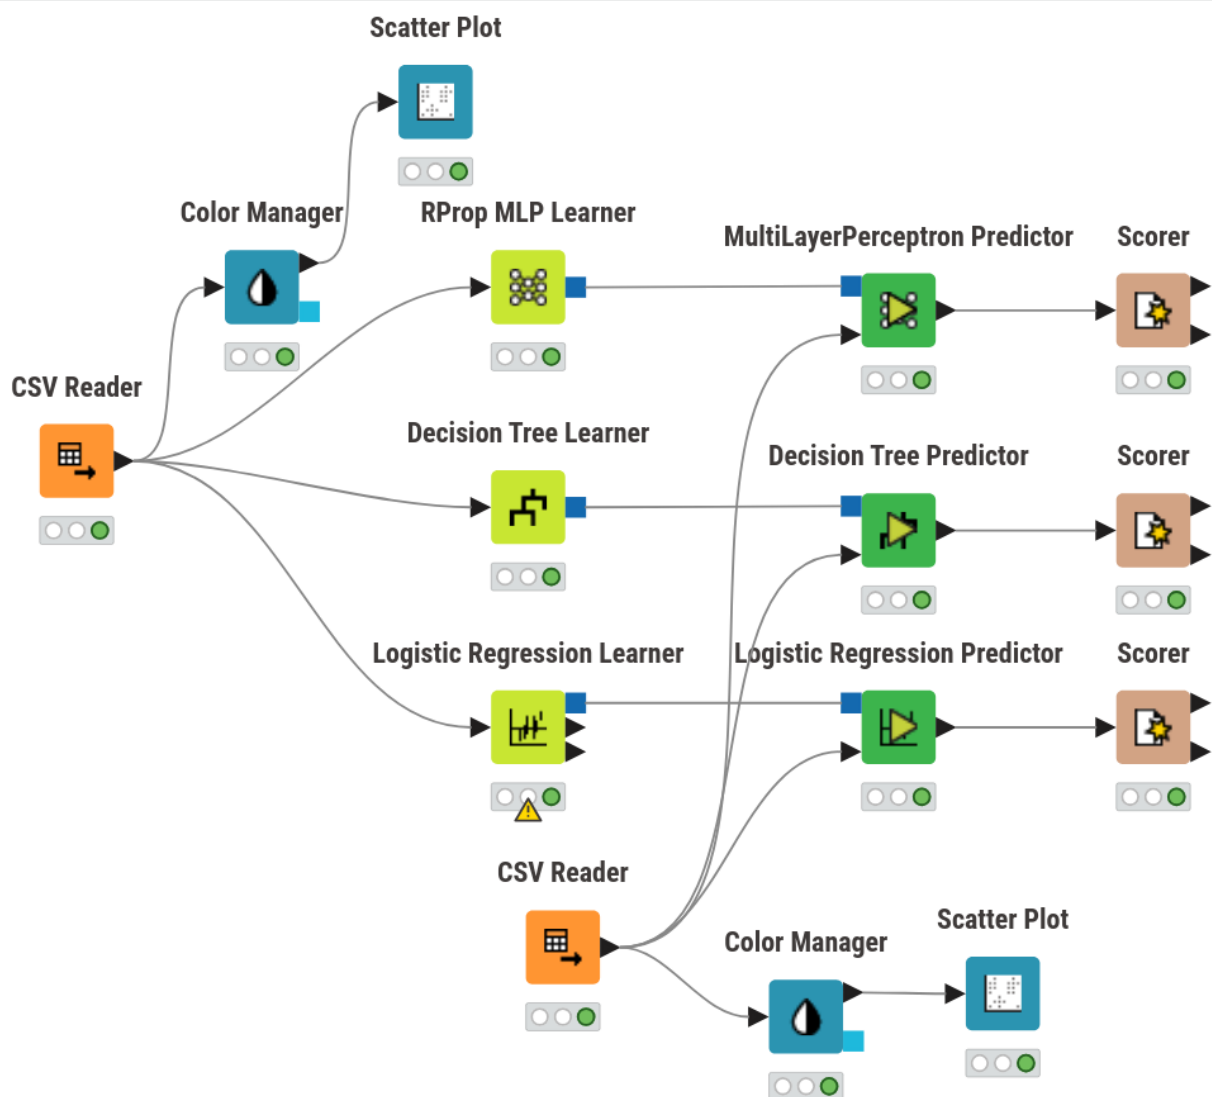
4 pav. CSV Reader mazgas nuskaito mokymosi duomenis, RProp MLP Learner apmoko daugiasluoksnį perceptroną, antrasis CSV Reader mazgas pateikia duomenis prognozavimui, MultiLayerPerceptron Predictor atlieka prognozes, o Scorer įvertina gautus rezultatus.



4 pav. Penktoji seka

6 ir 7

5 pav. Pirmasis CSV Reader mazgas nuskaito mokymo duomenis, kuriuos apdoroja trys skirtingi modeliai: RProp MLP Learner, Decision Tree Learner ir Logistic Regression Learner. Kiekvienas jų turi savo Predictor ir Scorer mazgus, kad būtų galima atlikti prognozes bei įvertinti rezultatus. Antrasis CSV Reader perduoda testavimo duomenis į Predictor mazgus. CSV Reader mazgai sujungti su Color Manager ir Scatter Plot, kad jų duomenis vizualizuoti.



5 pav. Šeštoji ir septintoji sekos

3.1. Daugiasluksnio perceptrono mokymo rezultatai:


- Klasifikavimo matrica 1 lentelė.
- Klasifikavimo tikslumo metrikos 2 lentelė.
- Paklaidos kitimas mokymosi priklausomai nuo epochos 6 pav.

1 lentelė. DNT mokymo klasifikavimo matrica.

40	0	0
0	39	1
0	1	39

2 lentelė. DNT mokymo bendros klasifikavimo tikslumo statistikos.

Metrika	Vertė
Tikslumas	98,33%
Precizija	98,33%
F1 rodiklis	98,33%
Atkūrimas	98,33%
Jautrumas	98,33%
Specifiškumas	99,17%



6 pav. Paklaida priklausomai nuo epochos

3.2. Daugiasluoksnių perceptrono testavimo rezultatai:

- Klasifikavimo matrica 3 lentelė.
- Klasifikavimo tikslumo metrikos 4 lentelė.

3 lentelė. DNT testavimo klasifikavimo matrica.

10	0	0
0	10	0
0	0	10

4 lentelė. DNT testavimo bendros klasifikavimo tikslumo statistikos.

Metrika	Vertė
Tikslumas	100%
Precizija	100%
F1 rodiklis	100%
Atkūrimas	100%
Jautrumas	100%
Specifiškumas	100%

3.3. Eksperimentai su hiperparametrais

Optimaliausi hiperparametrai:

Iteracijų skaičius: 1000;

Paslėptų sluoksnių skaičius: 2;

Paslėptų neuronų sluoksnyje skaičius: 10.

Tikslumas su šiais parametrais: 0,992.

- Iteracijų skaičius: 10;
Paslėptų sluoksnių skaičius: 1;
Paslėptų neuronų sluoksnyje skaičius: 10.
Gautas tikslumas: 0,725.
- Iteracijų skaičius: 10;
Paslėptų sluoksnių skaičius: 1;
Paslėptų neuronų sluoksnyje skaičius: 100.
Gautas tikslumas: 0,667.
- Iteracijų skaičius: 10;
Paslėptų sluoksnių skaičius: 10;
Paslėptų neuronų sluoksnyje skaičius: 10.
Gautas tikslumas: 0,333.
- Iteracijų skaičius: 10;
Paslėptų sluoksnių skaičius: 2;
Paslėptų neuronų sluoksnyje skaičius: 10.
Gautas tikslumas: 0,958.
- Iteracijų skaičius: 10;
Paslėptų sluoksnių skaičius: 3;

Paslėptų neuronų sluoksnyje skaičius: 10.

Gautas tikslumas: 0,658.

- Iteracijų skaičius: 100;

Paslėptų sluoksnių skaičius: 1;

Paslėptų neuronų sluoksnyje skaičius: 10.

Gautas tikslumas: 0,975.

- Iteracijų skaičius: 1000;

Paslėptų sluoksnių skaičius: 2;

Paslėptų neuronų sluoksnyje skaičius: 10.

Gautas tikslumas: 0,992.

3.4. Testavimo duomenų įrašų klasifikavimas

Priskiriant klases testavimo duomenims remiantis ištreniruotu DNT modeliu gavome duomenis pateiktus 5 lentelė. Čia Lapk. – lapkotis; Žiedl. – žiedlapis.

5 lentelė. Iris duomenų lentelė su savybėmis, klasėmis ir priskyrimais.


Lapk. ilgis	Lapk. plotis	Žiedl. ilgis	Žiedl. plotis	Klasė	P Iris-setosa	P Iris-versicolor	P Iris-virginica	Priskirta klasė
5.1	3.5	1.4	0.3	Iris-setosa	1.0	0.0	0.0	Iris-setosa
5.7	3.8	1.7	0.3	Iris-setosa	1.0	0.0	0.0	Iris-setosa
4.6	3.6	1.0	0.2	Iris-setosa	1.0	0.0	0.0	Iris-setosa
5.1	3.3	1.7	0.5	Iris-setosa	1.0	0.0	0.0	Iris-setosa
5.2	3.5	1.5	0.2	Iris-setosa	1.0	0.0	0.0	Iris-setosa
4.9	3.1	1.5	0.1	Iris-setosa	1.0	0.0	0.0	Iris-setosa
5.5	3.5	1.3	0.2	Iris-setosa	1.0	0.0	0.0	Iris-setosa
5.1	3.4	1.5	0.2	Iris-setosa	1.0	0.0	0.0	Iris-setosa
4.5	2.3	1.3	0.3	Iris-setosa	1.0	1.0	0.0	Iris-versicolor
5.3	3.7	1.5	0.2	Iris-setosa	1.0	0.0	0.0	Iris-setosa
7.0	3.2	4.7	1.4	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.5	2.3	4.0	1.3	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.6	3.0	4.5	1.5	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
6.8	2.8	4.8	1.4	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.5	2.4	3.7	1.0	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.5	2.6	4.4	1.2	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.0	2.3	3.3	1.0	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.6	2.7	4.2	1.3	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
6.2	2.9	4.3	1.3	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
5.1	2.5	3.0	1.1	Iris-versicolor	0.0	1.0	0.0	Iris-versicolor
6.3	2.9	5.6	1.8	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.5	3.0	5.8	2.2	Iris-virginica	0.0	0.0	1.0	Iris-virginica
5.7	2.5	5.0	2.0	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.0	2.2	5.0	1.5	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.4	2.8	5.6	2.1	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.9	3.1	5.1	2.3	Iris-virginica	0.0	0.0	1.0	Iris-virginica
5.8	2.7	5.1	1.9	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.7	3.3	5.7	2.5	Iris-virginica	0.0	0.0	1.0	Iris-virginica
6.7	3.0	5.2	2.3	Iris-virginica	0.0	0.0	1.0	Iris-virginica
5.9	3.0	5.1	1.8	Iris-virginica	0.0	0.0	1.0	Iris-virginica

3.5. Duomenų atvaizdavimas dekartio koordinatų sistemoje


Kad pavaizduotume, kaip parametrai sąveikauja tarpusavyje ir leidžia atpažinti klases naudojame dekartio koordinatų sistemas. Pateikiame sistemas šiems parametrų junginiams:

- Lapkočio ilgis ir plotis 7 pav.
- Lapkočio ir žiedlapio ilgiai 8 pav.
- Žiedlapio ilgis ir plotis 9 pav.


- Lapkočio ir žiedlapio pločiai 10 pav.




7 pav. Lapkočio ilgis ir plotis



8 pav. Lapkočio ir žiedlapio ilgiai



9 pav. Žiedlapio ilgis ir plotis



10 pav. Lapkočio ir žiedlapio pločiai

3.6. Metodų palyginimas

- Logistic Regression: pasižymi aukštu tikslumu ir turi mažiausiai klaidingų teigiamų ar klaidingų neigiamų klasifikacijų. Tikslumas: 0.9833. Preciziškumo metrikos kiekvienai klasei: Iris-setosa - 1.0, Iris-versicolor - 1.0, Iris-virginica - 0.9523.
- Decision Tree: rodikliai taip pat labai artimi; daugumoje atvejų klasifikuoja taisyklingai. Tikslumas: 0.975. Šiuo modeliu prasčiausiai pasirodė preciziškumo metrikos: Iris-setosa - 1.0, Iris-versicolor - 0.9743, Iris-virginica - 0.9512.
- RProp MLP: galutiniai rezultatai labai geri su nedaug klaidų. Tikslumas: 0.975. Preci-

ziškumo metrikos kiekvienai klasei: Iris-setosa - 1.0, Iris-versicolor - 1.0, Iris-virginica - 0.9302.

Visų modelių metrikos labai panašios, todėl negalime atskirti vieno geriausio.

4. Išvada

Dokumente aprašytas dirbtinio neuronų tinklo mokymo procesas naudojant irisų gėlių duomenis. Patikrinome, kaip gerai mūsų modelis atpažįsta skirtingas veisles. Taip pat, atradome optimaliausius hiperparametrus, kuriuos galime naudoti šiame modelyje. Toliau palyginome įvairius DNT mokymo metodus, kurie pasirodė beveik nesiskiriantys.